

# Algorytm SHADE

Dawid Płodowski

Wydział Matematyki i Nauk Informatycznych

18-03-2023

# Differential Evolution (DE)

**Pomysł:** Wylosujemy punkty w przestrzeni (populacja). Pozwólmy im, zgodnie z ustaloną strategią, losowo łączyć się ze sobą (mutacja) z każdą kolejną iteracją (generacja). Każda mutacja to dodanie do oryginalnego punktu przeskalowanego kierunku wyznaczonego poprzez inne punkty. To, czy mutacja zajdzie, jest wyznaczane losowo.

## Notacja

- $N$  - liczność populacji
- $U$  - zbiór strategii mutacji
- $F$  - skala mutacji
- $CR$  - *Crossover rate*, częstość mutacji
- $G$  - numer generacji mutacji

# Przykładowe strategie

Częścią wspólną każdej strategii jest losowanie permutacji populacji  $(r_1, \dots, r_N)$ . Zmutowane punkty oznaczamy  $(\nu_1, \dots, \nu_N)$  i wyznaczamy za pomocą strategii:

## Strategie

- **rand/1**:  $\nu_{i,G} = x_{r_1,G} + F(x_{r_2,G} - x_{r_3,G})$
- **best/1**:  $\nu_{i,G} = x_{best,G} + F(x_{r_1,G} - x_{r_2,G})$
- **current-to-best/1**:  
$$\nu_{i,G} = x_{i,G} + F(x_{best,G} - x_{i,G}) + F(x_{r_1,G} - x_{r_2,G})$$

## Crossover rate

Po dokonaniu mutacji decydujemy się, które z nich uwzględnimy w kolejnej generacji. **Uwaga:** decyzja dotyczy elementu wektora, nie całego punktu!

$$u_{j,i,G} = \begin{cases} \nu_{j,i,G}, & CR > \text{unif}(0, 1) \\ x_{j,i,G}, & \text{w.p.p} \end{cases} \quad (1)$$

Jeżeli mutacja była dla nas pomyślna to ją zachowujemy, w przeciwnym wypadku powracamy do oryginalnego punktu:

$$x_{i,G+1} = \begin{cases} u_{i,G}, & f(u_{i,G}) < f(x_{i,G}) \\ x_{i,G}, & \text{w.p.p} \end{cases} \quad (2)$$

# Problemy DE

Dla całego procesu wybieramy licznosc ( $N$ ), strategię ( $U_i$ ), skalę mutacji ( $F$ ) i częstość mutacji ( $CR$ ). Parametry globalne mogą być w pewnych miejscach przestrzeni nieadekwatne, niektóre mogą charakteryzować się złym dobraniem do konkretnego problemu optymalizacyjnego.

# JADE

**JADE** to prekursor algorytmu **SHADE**. Rozwiązuje problem globalnych parametrów przydzielając dla każdego osobnika z osobna dynamicznie parametry mutacji.

## Nowa strategia

**current-to-pbest/1:**  $\nu_{i,G} = x_{i,G} + F(x_{pbest,G} - x_{i,G}) + F(x_{r1,G} - x_{r2,G})$

$x_{pbest}$  oznacza losowo wybrany punkt z  $p$  najlepszych.

# Dynamiczna zmiana parametrów

Dla każdego osobnika z populacji stosowany jest algorytm:

- w pierwszej iteracji zainicjalizuj  $F_i = 0.5$  i  $CR_i = 0.5$
- wyznacz średnią wartość  $mean_L(F)$  i  $mean_A(CR)$  dla tych osobników, których mutacja zakończyła się sukcesem (nie została odrzucona w ostatnim kroku)
- wyznacz średnią wartość  $\mu_{F_G} = c\mu_{F_{G-1}} + (1 - c)mean_L(F)$  i analogicznie  $\mu_{CR}$  [ $n$  - tzw. *learning\_rate*, parametr algorytmu]
- wylosuj nowe  $F_i$  i  $CR_i$  z rozkładów  $Cauchy(\mu_F, 0.1)$  i  $N(\mu_{CV}, 0.1)$  odpowiednio
- powtarzaj kroki 2-4 w kolejnych iteracjach

$mean_A$  oznacza średnią arytmetyczną, a  $mean_L$  średnią Lehmera.

## Opcjonalne archiwum

W tradycyjnym algorytmie podczas każdej generacji "usuwamy" poprzednią populację. Jeżeli korzystamy z archiwum ( $P$ ), osobnik, który nie przetrwał (znaleźliśmy lepszy punkt na jego podstawie), trafia do archiwum. Punkt  $x_{r_2, G}$  z poprzedniego slajdu losowany jest z sumy zbioru  $X$  i  $P$ . Co daje nam taka strategia:

- zachowujemy punkty, które mogłyby być potencjalnie obiecujące, ale źle zmutowały
- zwiększamy wielkość zbioru, z którego losujemy mutacje (większa różnorodność)



# Problemy JADE

W algorytmie JADE dobieramy dynamicznie parametry na podstawie podpopulacji, której udało się ewoluować z sukcesem. Probabilistycznie możliwe jest, że taka podpopulacja miała bardzo złe parametry i jej "sukces" był przypadkowy. Potrzebujemy algorytmu, który będzie odporny na pojedyncze "szczęśliwe" generacje, które bazują na złych parametrach.

# SHADE

SHADE (*Success History DE*) rozwija algorytm JADE o zachowywanie informacji o poprzednich sukcesach.

- jeżeli parametry sprawdziły się w pewnej generacji, kolejne (nawet odległe) generacje mogą z nich ponownie skorzystać
- "szczęśliwe" parametry, które w rzeczywistości nie są odpowiednie do zadania nie determinują kolejnych generacji
- zwiększenie entropii algorytmu - mniejsza szansa na zatrzymanie się na niekorzystnych parametrach

# Pamięć poprzednich generacji

Zamiast:

$$\mu_F, \mu_{CR}$$

Zdefiniujemy:

$$M_F = (M_{F,1}, \dots, M_{F,H}), \quad M_{CR} = (M_{CR,1}, \dots, M_{CR,H})$$

Podczas tworzenia nowej generacji wybierzmy parametry  $\mu_F, \mu_{CR}$  ze zbiorów  $M_F, M_{CR}$ . Wyznaczmy, tak samo jak w JADE, nowe parametry  $F$  i  $CR$  i nadpiszmy nim  $M_{F,k}, M_{CR,k}$ , gdzie  $k = \text{mod}(G, H)$ .

## Wyznaczanie średniej średniej

Zamiast wyznaczać zwykłą średnią, możemy nadać jej odpowiednie wagi, które będą faworyzowały szczególnie "wybitne" osobniki, tzn. te, które w trakcie trwania generacji najbardziej zmniejszyły wartość  $f(x)$ .

### Średnia ważona

$$mean_{WA}(S_{CR}) = \sum_{k=1}^{|S_{CR}|} \omega_k * S_{CR,k}$$

$$mean_{WL}(S_F) = \frac{\sum_{k=1}^{|S_{CR}|} \omega_k * S_{F,k}^2}{\sum_{k=1}^{|S_{CR}|} \omega_k * S_{F,k}}$$

$$\omega_k = \frac{\Delta f_k}{\sum_{i=1}^{|S_{CR}|} \Delta f_i}$$

# Dynamiczna zmiana *current-to-pbest*

Z jednej strony zmiana w kierunku najlepszego punktu jest intuicyjnie uzasadniona; z drugiej strony ryzykujemy, że najlepszy punkt utknał w minimum lokalnym i cała reszta populacji również tam trafi. Kompromisem pomiędzy tymi podejściami jest losowanie  $p$  dla każdego punktu z pewnego rozkładu  $rand[p_{min}, 0.2]$ .

# Benchmark

$F$	SHADE	CoDE	EPSDE	JADE	dynNPjDE
	Mean (Std Dev)	Mean (Std Dev)	Mean (Std Dev)	Mean (Std Dev)	Mean (Std Dev)
$F_1$	<b>0.00e+00 (0.00e+00)</b>	<b>0.00e+00 (0.00e+00)</b> ≈	<b>0.00e+00 (0.00e+00)</b> ≈	<b>0.00e+00 (0.00e+00)</b> ≈	<b>0.00e+00 (0.00e+00)</b> ≈
$F_2$	9.00e+03 (7.47e+03)	9.78e+04 (4.81e+04)–	1.37e+06 (5.23e+06)–	<b>7.67e+03 (5.66e+03)</b> ≈	9.52e+04 (4.09e+04)–
$F_3$	<b>4.02e+01 (2.13e+02)</b>	1.08e+06 (3.03e+06)–	1.75e+08 (5.39e+08)–	4.71e+05 (2.35e+06)–	1.71e+06 (2.54e+06)–
$F_4$	<b>1.92e-04 (3.01e-04)</b>	8.18e-02 (1.09e-01)–	8.08e+03 (2.56e+04)–	6.09e+03 (1.33e+04)–	4.76e+01 (4.75e+01)–
$F_5$	<b>0.00e+00 (0.00e+00)</b>	<b>0.00e+00 (0.00e+00)</b> ≈	<b>0.00e+00 (0.00e+00)</b> ≈	<b>0.00e+00 (0.00e+00)</b> ≈	<b>0.00e+00 (0.00e+00)</b> ≈
$F_6$	<b>5.96e-01 (3.73e+00)</b>	4.16e+00 (9.00e+00)–	9.27e+00 (1.33e+00)–	2.07e+00 (7.17e+00)≈	1.19e+01 (1.66e+00)–
$F_7$	4.60e+00 (5.39e+00)	9.32e+00 (6.34e+00)–	5.88e+01 (4.29e+01)–	3.16e+00 (4.13e+00)≈	<b>2.62e+00 (1.59e+00)</b> ≈
$F_8$	<b>2.07e+01 (1.76e-01)</b>	2.08e+01 (1.18e-01)≈	2.09e+01 (5.32e-02)–	2.09e+01 (4.93e-02)–	2.10e+01 (3.98e-02)–
$F_9$	2.75e+01 (1.77e+00)	<b>1.45e+01 (2.90e+00)</b> +	3.50e+01 (4.21e+00)–	2.65e+01 (1.96e+00)+	2.20e+01 (5.12e+00)+
$F_{10}$	7.69e-02 (3.58e-02)	<b>2.71e-02 (1.50e-02)</b> +	1.02e-01 (5.65e-02)–	4.04e-02 (2.37e-02)+	3.63e-02 (2.34e-02)+
$F_{11}$	<b>0.00e+00 (0.00e+00)</b>	<b>0.00e+00 (0.00e+00)</b> ≈	1.95e-02 (1.39e-01)≈	<b>0.00e+00 (0.00e+00)</b> ≈	<b>0.00e+00 (0.00e+00)</b> ≈
$F_{12}$	2.30e+01 (3.73e+00)	3.98e+01 (1.21e+01)–	4.94e+01 (9.28e+00)–	<b>2.29e+01 (5.45e+00)</b> ≈	4.07e+01 (8.81e+00)–
$F_{13}$	5.03e+01 (1.34e+01)	8.04e+01 (2.74e+01)–	7.68e+01 (1.72e+01)–	<b>4.67e+01 (1.37e+01)</b> ≈	7.10e+01 (1.72e+01)–
$F_{14}$	3.18e-02 (2.33e-02)	3.60e+00 (4.09e+00)–	3.99e-01 (6.00e-01)–	2.86e-02 (2.53e-02)≈	<b>9.39e-03 (1.40e-02)</b> +
$F_{15}$	<b>3.22e+03 (2.64e+02)</b>	3.36e+03 (5.31e+02)–	6.75e+03 (7.60e+02)–	3.24e+03 (3.17e+02)≈	4.39e+03 (4.72e+02)–
$F_{16}$	9.13e-01 (1.85e-01)	<b>3.38e-01 (2.03e-01)</b> +	2.48e+00 (2.88e-01)–	1.84e+00 (6.27e-01)–	2.32e+00 (2.83e-01)–
$F_{17}$	<b>3.04e+01 (3.83e-14)</b>	3.04e+01 (1.17e-02)–	3.04e+01 (2.51e-02)–	3.04e+01 (1.95e-14)–	3.04e+01 (1.78e-03)≈
$F_{18}$	7.25e+01 (5.58e+00)	<b>6.69e+01 (9.23e+00)</b> +	1.37e+02 (1.12e+01)–	7.76e+01 (5.91e+00)–	1.35e+02 (1.24e+01)–
$F_{19}$	1.36e+00 (1.20e-01)	1.61e+00 (3.58e-01)–	1.84e+00 (2.00e-01)–	1.44e+00 (8.71e-02)–	<b>1.27e+00 (1.09e-01)</b> +
$F_{20}$	1.05e+01 (6.04e-01)	1.06e+01 (6.69e-01)≈	1.30e+01 (6.33e-01)–	<b>1.04e+01 (5.82e-01)</b> ≈	1.13e+01 (4.14e-01)–
$F_{21}$	3.09e+02 (5.65e+01)	3.02e+02 (9.02e+01)≈	3.05e+02 (8.06e+01)≈	3.04e+02 (6.68e+01)≈	<b>2.94e+02 (8.29e+01)</b> ≈
$F_{22}$	9.81e+01 (2.52e+01)	1.17e+02 (9.96e+00)–	3.09e+02 (1.12e+02)–	<b>9.39e+01 (3.08e+01)</b> ≈	1.03e+02 (2.57e+01)–
$F_{23}$	3.51e+03 (4.11e+02)	3.56e+03 (6.12e+02)≈	6.74e+03 (8.20e+02)–	<b>3.36e+03 (4.01e+02)</b> ≈	4.36e+03 (4.61e+02)–
$F_{24}$	2.05e+02 (5.29e+00)	2.21e+02 (9.28e+00)–	2.91e+02 (7.08e+00)–	2.17e+02 (1.57e+01)–	<b>2.04e+02 (4.22e+00)</b> ≈
$F_{25}$	2.59e+02 (1.96e+01)	2.57e+02 (6.55e+00)≈	2.99e+02 (3.29e+00)–	2.74e+02 (1.06e+01)–	<b>2.55e+02 (7.91e+00)</b> ≈
$F_{26}$	2.02e+02 (1.48e+01)	2.18e+02 (4.48e+01)–	3.56e+02 (6.49e+01)–	2.15e+02 (4.11e+01)≈	<b>2.00e+02 (3.06e-03)</b> +
$F_{27}$	<b>3.88e+02 (1.09e+02)</b>	6.20e+02 (1.01e+02)–	1.21e+03 (7.42e+01)–	6.70e+02 (2.40e+02)–	3.90e+02 (9.12e+01)≈
$F_{28}$	<b>3.00e+02 (0.00e+00)</b>	<b>3.00e+02 (0.00e+00)</b> ≈	<b>3.00e+02 (0.00e+00)</b> ≈	<b>3.00e+02 (0.00e+00)</b> ≈	<b>3.00e+02 (0.00e+00)</b> ≈
	+	4	0	2	5
	-	15	23	10	13
	≈	9	5	16	10

Rysunek: Benchmark algorytmów.

# Bibliografia

- *Success-History Based Parameter Adaptation for Differential Evolution*, Ryoji Tanabe, Alex Fukunaga,  
<http://metahack.org/CEC2013-SHADE.pdf>