O wybieraniu najlepszych funkcji optymalizacyjnych

Łukasz Grabarski

Plan prezentacji

- Wprowadzenie
- 2 CEC
- **3** BBOB
- Testy statystyczne

Metaheurystyka

Wprowadzenie

Metaheurystyka – ogólny algorytm (heurystyka) do rozwiązywania problemów obliczeniowych. Algorytmu metaheurystycznego można używać do rozwiązywania dowolnego problemu, który można opisać za pomoca pewnych definiowanych przez ten algorytm pojeć.

Metaheurystyka

Wprowadzenie

- Jak znaleźć najlepszy algorytm?
- Na jakiej podstawie porównywać ze sobą algorytmy?



Metaheurystyka

Wprowadzenie

- Jak znaleźć najlepszy algorytm?
- Na jakiej podstawie porównywać ze sobą algorytmy?

Odpowiedź: Benchmarki i testy



Dlaczego benchamarki?

- Uważa się je za podstawę do opracowywania bardziej złożonych problemów optymalizacyjnych np. wielokryterilanych
- Muszą one symulować stopień trudności rzeczywistych problemów optymalizacyjnych w świecie rzeczywistym.
- Muszą być w stanie wykryć słabości i mocne strony nowych algorytmów optymalizacyjnych, które znacząco się poprawiły w ciągu ostatnich kilku lat.

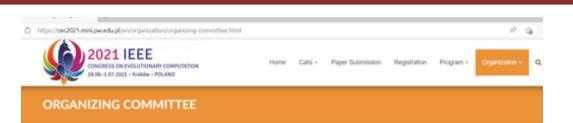
CEC - to znaczy?

CEC (ang. "IEEE Congress on Evolutionary Computation") to coroczna konferencja poświęcona algorytmom ewolucyjnym i innym algorytmom heurystycznym. Konferencja ta organizowana jest przez Instytut Inżynierów Elektryków i Elektroników (IEEE).

CEC - to znaczy?

Benchmarki służą do oceny skuteczności algorytmów optymalizacji i porównywania wyników różnych algorytmów na tych samych zestawach testowych. CEC Benchmark Functions składają się z 28 funkcji testowych, które zostały zaprojektowane specjalnie dla konkursów optymalizacyjnych w ramach tejże konferencji.

CEC 2021 - Kraków



General Co-Chair

General Co-Chair

Program Co-Chair

Program Co-Chair

Technical Co-Chair

Technical Co-Chair



Jacek Mańdziuk



Hussein Abbass



Yew-Soon Ong



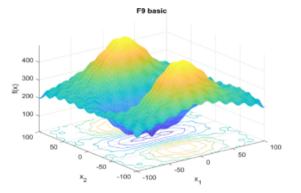
Hemant Singh



Daniel Ashlock

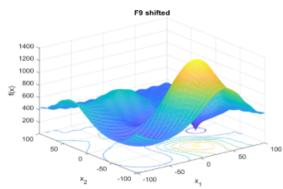


Oscar Cordón



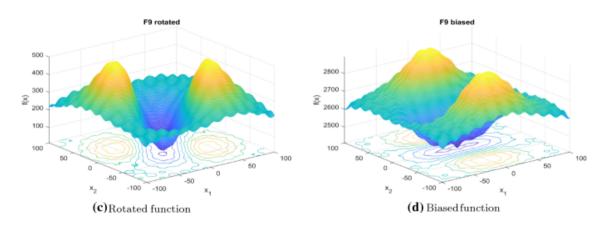
(a) Basic function

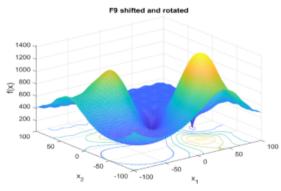




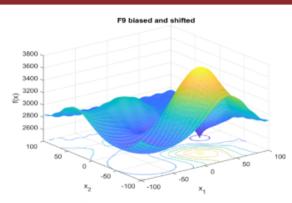
(b) Shifted function



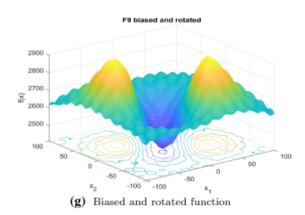




(e) Shifted and rotated function



(f) Biased and shifted function



F9 biased, shifted, and rotated 3800 3600 3400 3000 2800 2600 100 50 100 50 -100

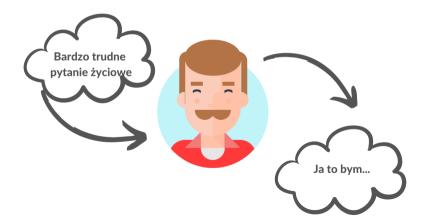
BBO - życiowo

Wprowadzenie



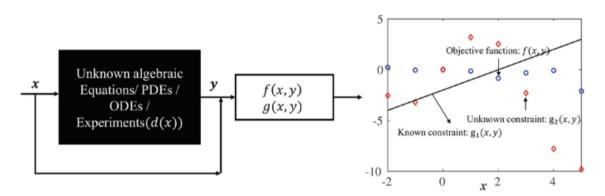
BBO - życiowo

Wprowadzenie



BBOB

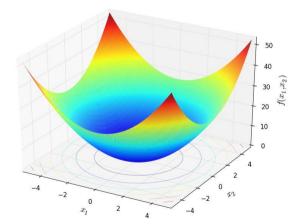
BBO - formalniej



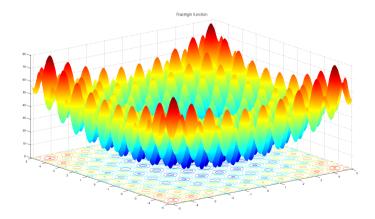
BBOB - co to?

Black Box Optimization Benchmark (BBOB) to zbiór testów, które służą do oceny skuteczności algorytmów optymalizacji globalnej. Jest to benchmark, ponieważ zawiera zestaw standardowych funkcji celu, które pozwalają porównać wyniki różnych algorytmów na tych samych danych testowych.

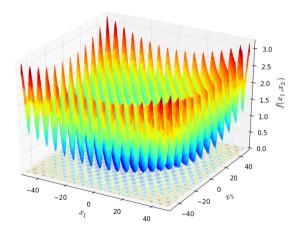
Sphere Function



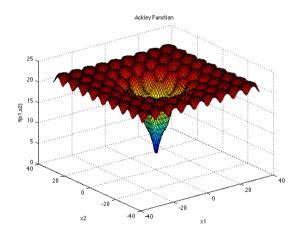
Rastrigin Function



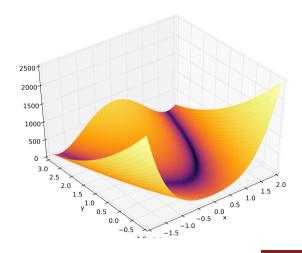
Griewank Function



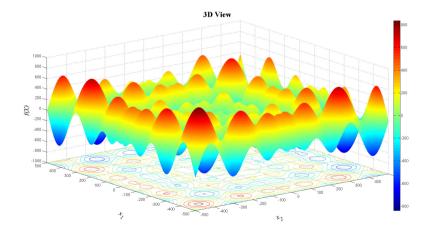
Ackley Function



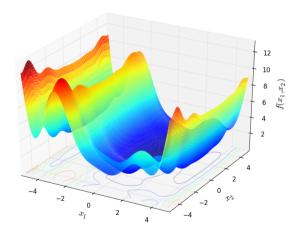
Rosenbrock (banana) Function



Schwefel Function



Levy Function



O testach statystycznych w ogóle

Test statystyczny

Testem statystycznym nazywamy statystykę $\varphi: X \to 0, 1$, której wartość 1 interpretujemy jako wskazanie odrzucenia hipotezy zerowej, natomiast wartość 0 — jako brak podstaw do odrzucenia hipotezy zerowej.

O testach statystycznych w ogóle

Hipoteza

Hipoteza (gr. hypóthesis = założenie) — zdanie przyjęte jako założenie, w celu wyjaśnienia jakiegoś zjawiska i wymagające sprawdzenia. Zazwyczaj mamy **hipotezę zerową** H_0 i odpowiadającą jej **hipotezę alternatywną** H_1 .

Jak sprawdzać hipotezy?

- Stawiamy hipotezę zerową H_0 i alternatywną H_1
- Ustalamy model matematyczny
- f o Przyjmujemy poziom istotności lpha
- Liczymy wartość statystyki testowej T
- **5** Liczymy wartość istotności testu p (ang. p value)
- **6** Decydujemy: jeśli $p \leqslant \alpha$ odrzucamy H_0

Test Kołmogorowa - Smirnowa

Założenia

Weźmy dwie próbki proste z ciągłych rozkładów:

$$X = (X_0, ..., X_n) F \text{ oraz } Y = (Y_0, ..., Y_m) G.$$

Interesuje nas problem: $H_0: F = G$ vs. $H_1 = F \neq G$

Test Kołmogorowa - Smirnowa

Statystyka testowa

Rozważamy następującą statystykę:

$$D_{n,m} = \sup_{x} |\widehat{F}_{n}(x) - \widehat{G}_{m}(x)|$$

Hipotezę zerową będziemy odrzucać na poziomie istotności α gdy: $D_{n,m} \geqslant D_{n,m}(1-\alpha)$, gdzie $D_{n,m}(1-\alpha)$ jest kwantylem rzędu $1-\alpha$ rozkładu statystyki testowej (przy założeniu prawdziwości H_0).

Reasumując...

Wprowadzenie



Tyle wystarczy...

Dziękuję za uwagę!

Bibliografia

https://link.springer.com/article/10.1007/s00521-022-07788-zSec8 https://pl.wikipedia.org/wiki/Metaheurystyka https://github.com/numbbo/coco/tree/v2.3 https://pages.mini.pw.edu.pl/ grzegorzewskip/